

东北财经大学
大学生创新创业训练计划项目
申 报 书

项 目 名 称: 用“魔盒”(MoE)模型,解金融风险之“锁”,开启安稳收益新篇。

项 目 类 别: 创新训练项目

项 目 负 责 人: 蒋雨静

负责人所在学院: 金融科技专业

东北财经大学创新创业学院制

项目名称		用“魔盒”（MoE）模型，解金融风险之“锁”，开启安稳收益新篇。				
项目所属专业		金融科技专业				
项目来源		1. 导师课题 2. 自主选题 3. 竞赛项目 4. 其他				
项目申报方式		1. 学生自主申报 2. 产教融合学科创新团队申报 <u>顺风顺水顺比赛</u> (团队名称)				
负责人	学号	姓名	学院	专业	手机号	邮箱
	2024212340	蒋雨静	金融科技	金融科技专业	13125450771	2330684373@qq.com
项目组成员	2024211460	刘祉彤	金融科技	金融科技专业	13332499363	Izt1503221752@qq.com
	2024211763	郑雨彤	金融科技	金融科技专业	15668904998	3979102909@qq.com
指导教师	工号	姓名	部门或工作单位	职称	职务	手机号
	20210007	刘壮	金融科技学院	副教授	系主任、金融科技训练营负责人、金融科技创新实验室负责人	13166662165
<div>项目简介</div> <p>本项目旨在构建一个基于 MoE 模型的风险管理智能系统，该系统能够自动识别、评估和预测潜在风险，为决策者提供及时、准确的风险管理建议。</p> <p>MoE 模型（混合专家模型）在风险管理问题中的应用主要体现在其能够处理复杂的非线性问题和自适应地分解问题的能力。MoE 模型通过将复杂问题分解为多个子问题，并由不同的专家模型分别处理，从而提高整体模型的准确性和鲁棒性。在风险管理中，MoE 模型可以用于优化决策支持工具，帮助识别和管理潜在的风险因素。例如，在金融系统中，MoE 模型可以用于最小化系统性风险，减少破产公司数量，并降低公司为避免破产而保持的储备金水平。这种方法通过优化神经网络模型的参数，能够更有效地预测和管理金融市场的风险。然而，MoE 模型在风险管理中的应用也面临一些挑战。例如，模型的泛化能力可能受到数据分布不均或存在其他复杂性的影响。此外，MoE 模型在处理大量参数时可能会出现过拟合的风险，需要通过正则化方法来增强模型的泛化能力。MoE 模型在风险管理中具有显著的优势，尤其是在处理复杂和动态变化的风险环境时。我们团队通过合理设计和优化 MoE 模型，有效提升了风险管</p>						

理的准确性和效率。

此外，对于问题输入过程中由于称呼简写或是名称使用不规范等问题导致的无法在数据库中检索到相关内容的问题，我们创建了 Language normalization System 对用户输入内容进行处理，以此来保证检索的准确性。通过本项目的实施，将构建一个高效、准确、可靠的风险管理智能系统，为企业决策者提供及时、准确的风险管理建议。该系统将提高企业的风险管理水平，降低运营风险，为企业的可持续发展提供有力保障。综上所述，利用 MoE 模型解决风险管理问题的项目具有广阔的应用前景和重要的实践意义。通过不断优化和完善系统功能和性能，将为企业带来更大的价值和效益。

一、项目背景及研究意义

1.项目背景

1.1.行业现状

在现代企业运营中，风险管理至关重要。传统风险管理方法往往依赖于人工分析和决策，不仅耗时耗力，还可能因人为因素导致判断失误。随着人工智能技术的不断发展，利用 AI 模型进行自动化风险管理成为可能。MoE 模型作为一种高效的深度学习架构，其在处理大规模数据和复杂模式识别方面的优势，使其成为解决风险管理问题的有力工具。MoE 模型在风险管理领域的应用可以提供更高效、更灵活的风险评估和预测工具，帮助企业和投资者更好地理解和管理风险。

1.2.社会需求

当前宏观经济形势的变化对风险管理提出了更高的要求。MoE 模型能够帮助金融机构更好地理解 and 预测市场变化，从而制定更有效的风险管理策略。此外，面对全球变局和不确定性，MoE 模型可以提供更灵活和全面的风险管理框架。在能源和水供应链优化等领域，MoE 模型可以通过多目标随机模型来处理经济目标函数与不同风险指标的关系，从而实现更高效的决策支持。这种方法有助于在经济和环境可行性之间找到平衡点，确保资源的合理分配和利用。MoE 模型在解决风险管理问题中的社会需求主要体现在提高决策准确性、应对复杂变化、支持多目标优化、提升模型泛化能力以及促进跨领域应用等方面。

1.3.团队背景

学校资源与支持，我们团队均来自金融科技学院，依靠学校提供的金融科技创新实验室，并有专业老师提供学术指导。

2.研究意义

2.1.提高风险识别准确性

MoE 模型能够处理海量的多源数据，如结构化的交易数据、非结构化的文本和音频信息等，挖掘其中的隐含信息和复杂关系，从而更全面、精准地识别各类金融风险。

2.2.提升风险管理效率

MoE 模型的强大计算能力和快速数据处理能力，可以缩短数据间发生连接与被计算的时间。

间，快速生成风险评估结果和决策建议，使金融机构能够及时应对风险变化，提高风险管理的及时性和有效性。

2.3.助力风险防控智能化

MoE 模型具备优秀的逻辑推理和智能决策能力，可自动化地进行风险监测、预警和控制，减少人为因素导致的风险判断失误和操作风险，实现风险管理的智能化和自动化。

2.4.优化风险定价策略

通过对大量客户数据和市场数据的分析，MoE 模型能够更准确地评估每个客户的违约概率和风险水平，从而为金融产品实现差异化定价提供依据，提高金融机构的定价能力和盈利能力，同时降低信用违约风险。

2.5.增强监管效能

金融监管部门可以利用 MoE 模型的数据分析和逻辑推理能力，更高效地监测市场动态、识别违规行为和潜在风险，提高对金融市场的监管水平和执法效率，维护金融市场的稳定和公平。

2.6.推动金融行业创新

MoE 模型技术为金融风险研究提供了新的思路和方法，促进金融机构在风险管理理念、技术应用和业务模式等方面的创新，推动金融行业的数字化转型和可持续发展。

二、研究内容和拟解决的关键问题

基于我国金融风险行业风险总体可控但局部风险仍存，数字化带来新挑战与机遇，信用风险需持续关注等现状，我们团队决心以降低金融风险为目标，利用 AI 大模型对金融风险进行预测并进行管理。我们将根据风险管理的三个步骤（风险识别，风险衡量，风险控制与处置），进行建模并逐步优化。在模型的优化过程中我们选取了多种算法对我们收集的数据进行处理，经过对比选出其中速度最快，偏离度最小，最具稳健性的模型（MoE 模型）。最终我们对所选模型再次进行优化，利用大数据对机器进行训练，最终使其达到降低金融风险的效果。

1.风险评估与预测

1.1.数据整合与特征提取

MOE 模型可以整合来自多个不同渠道的数据，如市场数据、企业财务数据、宏观经济数据等。对于每种数据类型，模型可以通过不同的“专家”（子模型）来提取其特征。例如，在评估信用风险时，一个“专家”可以专注于分析企业的资产负债表特征，另一个“专家”可以处理企业的现金流信息，最后综合这些特征来更准确地预测违约概率。

1.2.非线性关系建模

金融风险因素和风险结果之间往往存在复杂的非线性关系。MOE 模型能够有效地捕捉这种非线性，例如在市场风险中，股票价格、利率和汇率等因素对投资组合价值的影响不是简单的线性关系。MOE 通过多个专家的组合，能够拟合出复杂的风险评估函数，更好地预测资产价格波动带来的风险。

2.风险分类与分级

2.1.精准分类

在信用风险管理中，MOE 模型可以将客户的信用风险分为不同的类别，如低风险、中等风险和高风险。每个“专家”可以基于不同的标准（如还款历史、债务水平、行业风险等）进行分类，然后汇总这些分类结果，使得风险分类更加精准。

2.2.动态分级

金融风险是动态变化的，MOE 模型能够根据新的数据实时更新风险分级。例如，对于市场风险中的投资产品风险分级，当市场环境发生变化，如出现重大经济事件或政策调整时，模型中的各个专家可以及时调整评估指标权重，快速重新分级产品风险。

3.风险监测与预警

3.1.多维度监测

MOE 模型可以同时监测多个风险指标，通过不同的专家来跟踪不同类型的风险信号。例如，在操作风险管理中，一个专家可以监测内部流程中的交易执行风险，另一个专家可以关注外部网络安全风险对金融机构运营的影响。一旦某个专家发现异常信号，就可以及时发出预警。

3.2.自适应预警阈值

它能够根据不同的风险类别和市场环境，自适应地调整预警阈值。在流动性风险监测中，当市场资金紧张时期，模型可以自动降低流动性风险指标的预警阈值，提前发现可能出现的流动性危机。

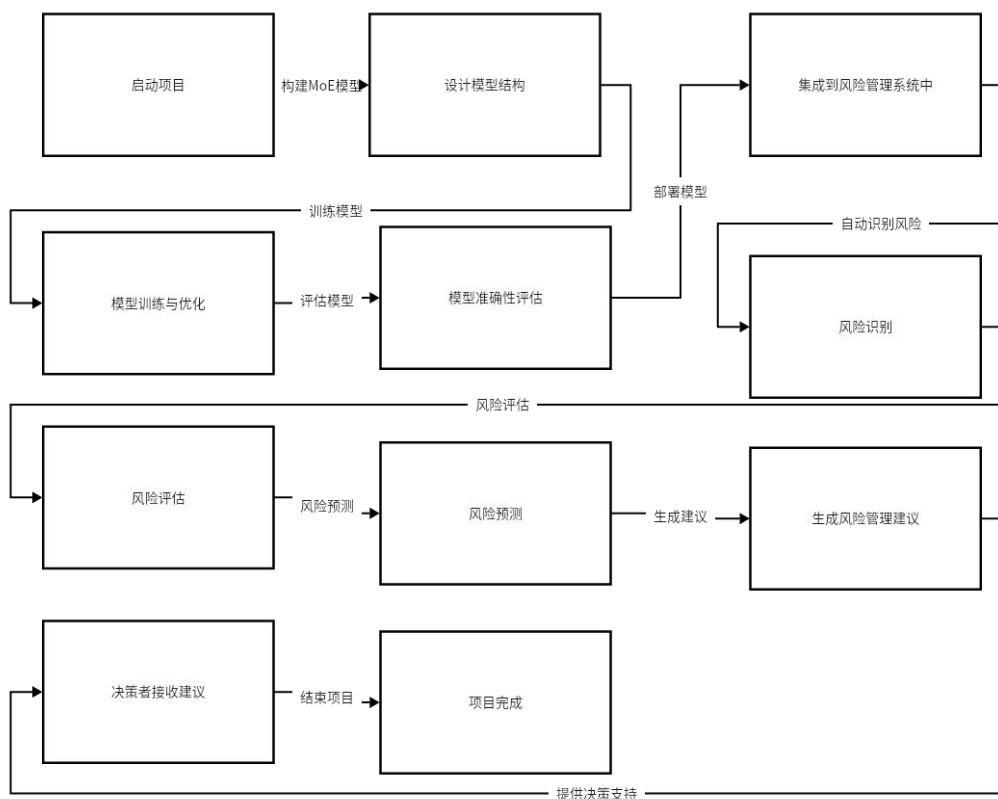



图 1 项目架构图



三、项目创新之处

1.对于模型的优化

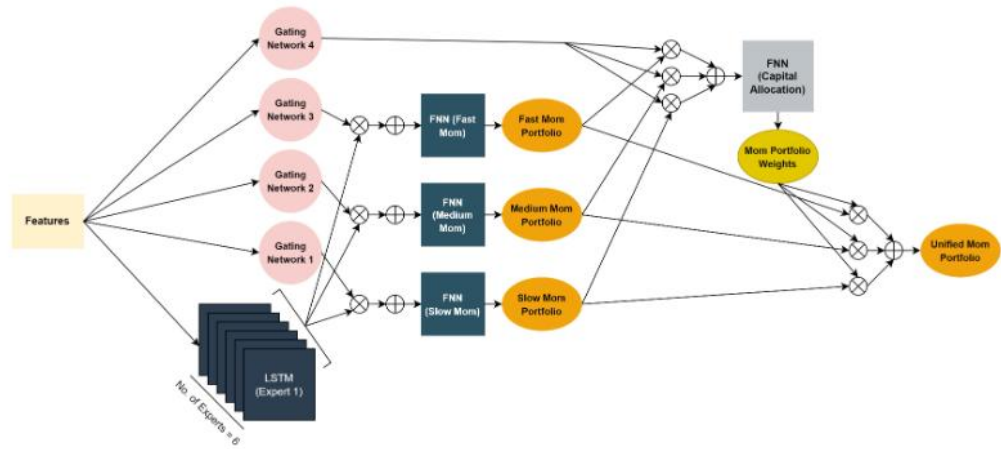


图 3MoE 模型数据处理架构图

基于本次问题数据计算的复杂性，我们团队依靠所处的金融科技创新实验室构建了一个MoE模型（Financial risk management MoE）（MoE：混合专家模型）对数据进行处理与计算，与传统的大型语言类模型（LLM）相比，Financial risk management MoE 更好的平衡了预训练效率和模型性能。MoE 框架通过动态路由输入到专家子集来促进模型的计算效率，允许在保持训练成本的同时进行大量模型缩放。除了效率高之外，混合专家架构的另一个特点是其模块化设计和学习范式。这种模块化旨在通过一个门控机制（gating mechanism）来确定每个专家模型的权重，从而将各个专家模型的输出进行组合，得到最终的输出结果（门控网络负责根据输入数据将任务分配给不同的专家。它学习如何根据输入的特征，为每个专家分配一个权重（或者概率）。例如，对于一个文本输入，门控网络会判断这个文本在语法、语义等各个维度的复杂程度，然后决定将主要的处理任务分配给哪些专家，以及每个专家参与处理的程度）。Financial risk management MoE 模型通过将原始FFN 替换为与路由器相结合的N个并行FFN来增强变压器。这些N个FFN也被称为专家，表示为 E_{n1} for $n \in [1, N]$ 。路由器 $g(-; G, k)$ ，由 G 和整数 k 参数化，将输入 x 分配给专家上的分数分布 $g(x; G, k) \in \mathbb{R}^N$ 。通常，路由器 g 由一个简单的线性层组成，后面跟着softmax和top-k函数。给定 $x \in \mathbb{R}^h$ ，输出 $y \in \mathbb{R}^r$ 是所有专家输出的加权求和：

$$y = \sum g_n(x; G, k) E_n(x)$$

以此我们可以通过对路由机制进行优化选择（影响 $g(x; G, k)$ 的值）以及改变并行FFN的个数（影响 $E_n(x)$ 的值）对最终Financial risk management MoE模型的结果的精确性进行提高。这保证了我们可以通过训练来影响不同专家模型的权重，可以根据任务需求灵活地分配计算资源，只激活与当前输入最相关的专家，避免了对所有参数进行不必要的计算，提高了资源的利用效率，从而使其达到我们预设的目标。

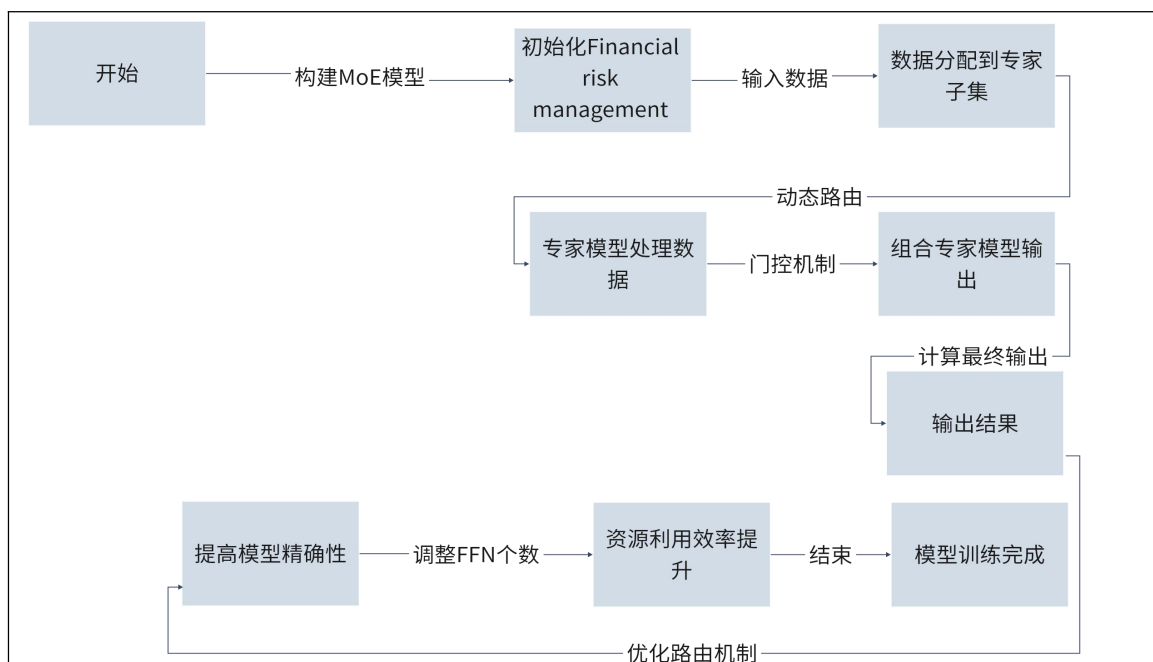


图 4 Financial risk management MoE 模型构建架构图

2.对于数据预处理的规范（建立 Language normalization System）

在数据输入至 Financial risk management MoE 模型前我们创新性地建立 Language normalization System 对语言进行处理来解决在问题输入过程中由于称呼简写或是名称使用不规范等问题导致的无法在数据库中检索到相关内容的问题。由于检索系统主要依靠关键词来识别和筛选相关信息。当语言不规范时，可能导致关键词拼写错误、用词不当或语法混乱，使得检索系统无法准确识别用户所输入的内容，从而错过真正与需求相关的信息，降低检索结果的相关性和准确性。由于检索系统在一定程度上尝试理解用户输入的语义，不规范的语言可能使句子结构混乱、表意不清，导致检索系统误解用户的意图，返回不符合实际需求的结果。此外，它还会增加检索次数和时间，从而使检索效率降低。

因为语言不规范可能导致初次检索结果不理想，用户往往需要多次修改检索词或重新表述问题，进行反复检索，这无疑会增加检索的次数和所花费的时间成本。比如，因为最初输入的检索词不规范，没有得到想要的结果，随后不得不逐个检查和修改关键词，重新发起检索，如此反复，使得整个检索过程变得冗长繁琐。而我们的 Language normalization System 就很好的解决了这个问题，这一系统通过在预训练期间对于用户问题输入过程中对于关键词的提取训练以及大数据中对于原有关键词的匹配。主要分为提取词汇特征和提取语义特征，前者除了常用的词袋模型，考虑提取更具代表性的词汇特征，如 TF-IDF（词频 - 逆文档频率）特征，它能突出重要的词汇，降低常见词的权重。还可以提取词的形态特征，如词的前缀、后缀等，对于识别词性和词义有一定帮助。后者利用词向量模型，如 Word2Vec、GloVe 等，将单词映射到低维向量空间，使具有相似语义的单词在向量空间中距离相近。此外，还可以通过构建知识图谱，获取更丰富的语义关系，以增强对语言的理解和识别。此外为了更好地保证检索的准确性，我们增加了数据的多样性，丰富了语料库：收集涵盖不同领域、主题、

文体和语言风格的文本数据，如新闻报道、学术论文、小说、社交媒体文本等。这样可以
让计算机接触到更广泛的语言表达方式，提高对各种语言现象的识别能力。同时增加了多语言
数据：纳入多种语言的语料，有助于机器学习不同语言的结构和特点，提升跨语言的语言
识别能力。

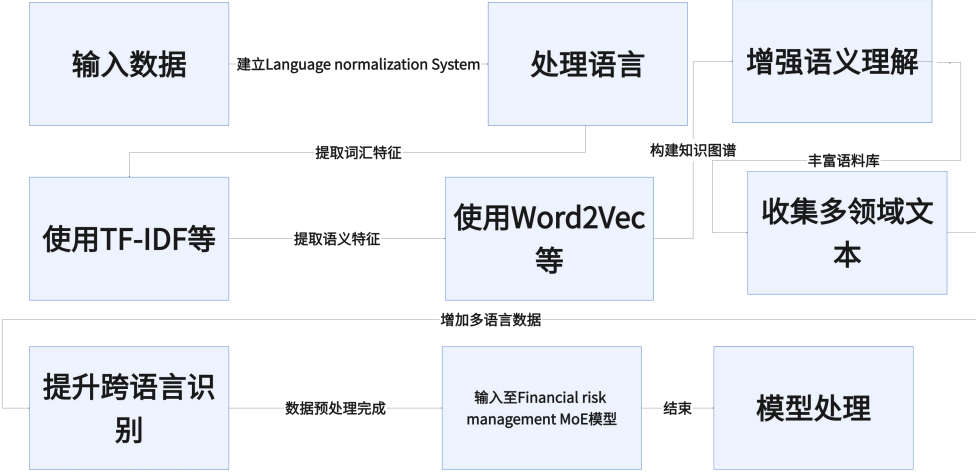


图 5 Language normalization System 构建流程

3.数据处理过程

我们将数据收集分为直接收集（调查法和测量法）和间接收集（文献查阅和网络爬取：
利用网络爬虫技术从互联网上抓取所需的数据）两类数据分析方式，以此对于企业的应收账
款占比，企业的短期债务和流动资产的比例，企业的财务指标、信用记录等信息进行收集。

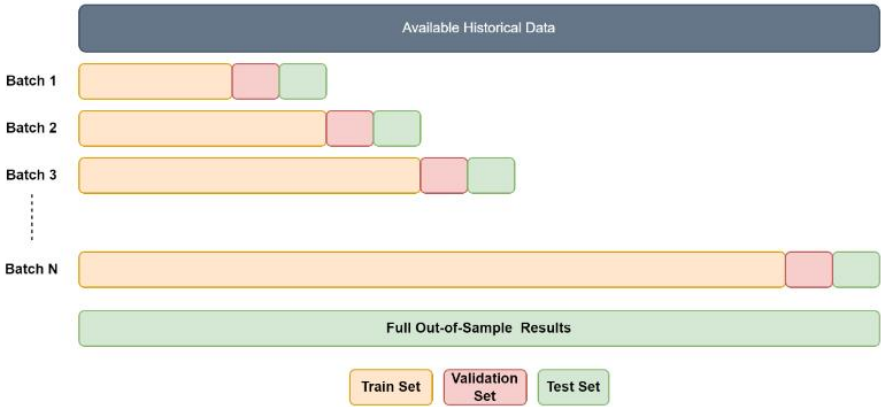


图 6 取样过程

3.1.明确数据需求

(1) 精准定义数据指标

在收集数据前，要对所需数据有清晰、明确的定义，避免模糊不清的概念。例如，在收
集”企业的短期债务和流动资产的比例“这一数据时明确是”短期“债务，并对短期这一概

念进行局限。

(2) 确定数据范围和来源

明确需要收集的数据涵盖哪些范围，以及从哪些渠道或来源获取这些数据最为可靠。比如研究某公司的财务指标，既要从公司官方网站查询，也要参考金融数据服务平台、政府监管机构网站等。

(3) 数据收集过程的质量控制

① 数据清洗与验证：网络上的数据往往比较杂乱，需要进行有效的清洗和验证，去除重复、错误和不相关的数据，以提高数据的准确性。

② 数据审核与验证：在数据收集的过程中，及时对收集到的数据进行审核和验证。可以采用逻辑检查、重复检查、数据对比等方法，发现并纠正数据中的错误和异常。

(4) 数据清理

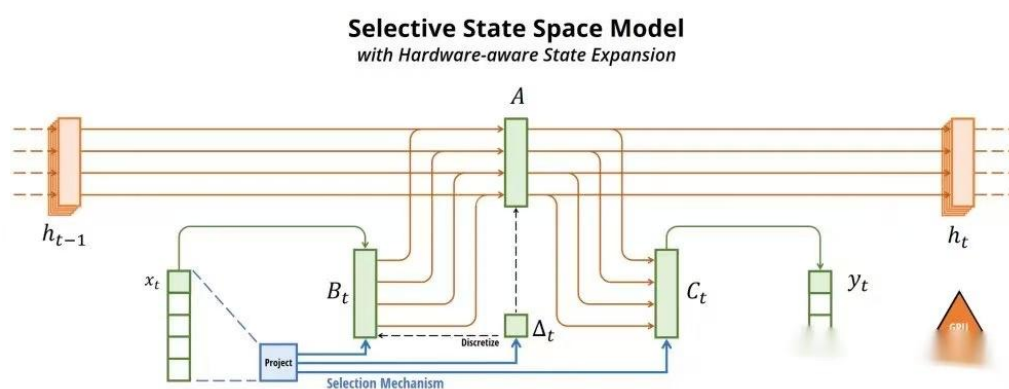


图 7 数据选择

对于数据收集的缺失值我们团队进行了以下两种处理：

① 删除法：当数据集中的缺失值数量较少且对整体分析影响不大时，可以直接删除包含缺失值的记录

② 插补法：通过一定的方法对缺失值进行填充。（均值插补、中位数插补、众数插补）

对于数据收集的重复值我们团队进行了以下两种处理：

① 完全重复值处理：通过数据去重工具或编写代码，识别并删除数据集中完全相同的记录。

② 部分重复值处理：对于部分字段相同的记录，需要根据具体情况进行处理。

对于数据收集的错误值我们团队进行了以下处理：

① 逻辑检查：通过设定数据的逻辑范围和规则，检查并修正不符合逻辑的数据。

② 统计分析：利用统计方法识别和处理异常值。例如，通过计算数据的均值和标准差，将超出一定范围的数据视为异常值进行处理。

此外为了进一步保证数据的可靠性，我们进一步创新性地优化了数据的处理：

为了提高对于离群点的敏感度，以及更好地适应数据特点，我们对比了 Minkowski 准则，

曼哈顿距离和欧几里得距离这三种距离度量方法。通过对比我们最终选择了 Minkowski 准则作为我们最终运用的距离度量方法。Minkowski 准则与曼哈顿距离比较：当 $p=1$ 时的 Minkowski 距离即曼哈顿距离，它计算的是两点在各个维度上的距离之和，就像在城市中沿着街道网格行走的距离，更注重维度之间的独立性，对离群点的敏感度相对较低。而一般的 Minkowski 距离（ p 不等于 1 时）则综合考虑了各个维度的距离，并且根据 p 值的不同，对离群点的敏感度也有所不同。Minkowski 准则与欧几里得距离比较：欧几里得距离（ $p=2$ 时的 Minkowski 距离）是最直观的距离度量，它计算的是两点之间的直线距离，在许多情况下表现良好。但在某些数据分布不均匀或存在离群点的情况下，欧几里得距离可能会受到较大影响。Minkowski 距离通过调整 p 值，可以在一定程度上克服欧几里得距离的局限性，更好地适应数据特点。

为了保证数据的稳健性，我们还运用了随机森林算法。在训练阶段，随机森林从原始训练数据中有放回地随机抽样，生成多个子数据集，分别训练不同的决策树。在预测阶段，对于新的数据点，每个决策树都会独立地做出预测，然后综合所有决策树的预测结果，通过投票（分类问题）或平均（回归问题）等方式得到最终的预测结果。

这一算法的准确性更高、抗过拟合能力更强、能处理更高维数据、可解释性更好、更能够评估特征重要性。

3.4 针对 MoE 模型的风险评估与应对方式

在研究过程中，我们发现 MoE 具有以下四种风险：

① 过拟合风险：MoE 模型由于其稀疏激活特性，虽然可以减少过拟合的风险，但在某些情况下，模型可能仍然容易受到训练数据中随机噪声的影响，从而增加过拟合的可能性。

② 隐私泄露风险：有研究表明，MoE 模型可能面临隐私泄露的风险。例如，通过精心设计的输入批次，攻击者可以操控 MoE 模型中的专家路由，从而泄露受害者的私密输入。

③ 模型泛化能力：尽管 MoE 模型通过多个专家的协同计算提高了鲁棒性，但每个专家专注于数据的较窄方面，可能导致在未见数据上的性能不佳。

④ 计算复杂性：MoE 模型由于其结构复杂性，可能需要更多的计算资源和时间来训练和运行，这在实际应用中可能是一个挑战。

针对以上问题，我们团队提出了创新性的解决方案：

(1) 针对过拟合风险的应对措施

我们对数据进行增强和清洗：

首先我们增加了数据的多样性，通过对原始数据进行旋转、翻转、缩放等操作，生成更多的训练样本，减少模型对特定噪声模式的学习。例如，在图像识别任务中，对图像进行各种角度的旋转和裁剪，使模型接触到更多的数据变化情况。

其次仔细清洗训练数据，去除明显的错误数据和异常值，降低随机噪声的影响。例如，在处理金融数据时，剔除不符合逻辑的交易记录，如金额为负数或过大的异常交易。

为了解决数据过拟合问题，我们采用正则化法和早停法（Early - Stopping）对数据进行处理：




图 8 早停法处理流程

我们使用了正则化法：

使用 L1 和 L2 正则化，对模型的参数进行约束。L1 正则化可以使部分参数变为 0，起到特征选择的作用；L2 正则化则限制参数的大小，防止模型过度拟合训练数据。在训练 MoE 模型时，可以在损失函数中加入正则化项。

采用 Dropout 技术，在训练过程中随机丢弃部分神经元的激活，使模型不能过度依赖某些神经元，从而增强模型的泛化能力。对于 MoE 模型中的每个专家模块，可以适当应用 Dropout 来减少过拟合。

此外我们还使用了早停法（Early - Stopping）：

在训练过程中，监测模型在验证集上的性能。当模型在验证集上的性能不再提升，甚至开始下降时，停止训练。这样可以避免模型过度拟合训练数据，因为随着训练轮数的增加，模型可能会开始学习训练数据中的噪声。

(2) 针对隐私泄露风险的应对措施

① 输入验证和过滤

在模型的输入层设置严格的验证机制，检查输入数据的合法性和合理性。例如，对于数值型输入，限制其取值范围；对于文本输入，利用 Language normalization System 进行校准。

过滤掉可能被用于攻击的异常输入批次，例如，对输入数据的分布进行监测，当发现输入数据的分布与正常分布差异较大时，拒绝这些输入。

② 模型加密和隐私保护技术：

采用同态加密等加密技术，使模型在加密状态下进行计算，保证输入数据的隐私性。这样，即使攻击者试图操控输入，也难以获取明文信息。

应用差分隐私技术，在模型的训练和推理过程中添加噪声，使攻击者难以通过微小的输

入变化来推断隐私信息。对于 MoE 模型，可以在专家路由等关键环节添加适当的噪声。

(3) 针对模型泛化能力的应对措施

① 多任务学习和预训练

采用多任务学习，让 MoE 模型同时学习多个相关任务，使专家模块能够学习到更通用的特征。例如，在自然语言处理中，让模型同时进行文本分类和命名实体识别任务，提高专家对文本不同方面的理解能力。

利用预训练技术，先在大规模的无监督数据上训练 MoE 模型，学习数据的一般特征，然后在具体任务的小数据集上进行微调。例如，在图像领域，先在大规模的图像数据集上进行无监督预训练，然后在特定的金融风险变化图任务上进行微调。

② 集成学习与模型融合

将 MoE 模型与其他不同类型的模型进行集成，如将其与简单的神经网络模型或决策树模型结合。在推理阶段，综合考虑不同模型的输出，提高模型在未见数据上的性能。

对多个训练好的 MoE 模型进行融合，例如，通过平均它们的输出或者采用投票机制，增强模型的泛化能力。

3.5.针对计算复杂性的应对措施

(1) 模型简化和量化

对 MoE 模型的结构进行简化，减少专家模块的数量或者降低每个专家模块的复杂度。通过分析任务需求，合理配置专家资源，去除不必要的复杂结构。

采用模型量化技术，将模型的参数从高精度的数据类型（如 32 位浮点数）转换为低精度的数据类型（如 8 位整数），减少存储和计算量，同时保持一定的模型性能。

(2) 硬件加速和分布式计算

使用专门的硬件加速设备，如 GPU（图形处理器）或 TPU（张量处理器），这些设备可以大大加快 MoE 模型的训练和运行速度。对于大规模的 MoE 模型，GPU 集群或分布式计算平台可以有效地分配计算任务，缩短计算时间。

优化模型的计算架构，采用并行计算和异步更新等策略，充分利用硬件资源，提高模型的计算效率。例如，在训练过程中，让不同的专家模块在不同的计算单元上并行训练。

四、预期研究成果

1.技术目标

1.1.高效数据处理与融合

构建强大的数据处理管道,实现对多源、异构金融数据的高速采集、清洗和整合。利用 MOE 模型的分布式架构优势,将海量数据分布式存储于不同节点,并设计高效的数据索引与查询机制,确保数据能够被快速检索和调用。开发先进的数据融合算法,能够将结构化的交易数据、财务报表数据与非结构化的新闻资讯、社交媒体数据等进行有机融合,为模型提供全面、准确的输入信息,以提升风险评估的准确性和完整性。

1.2.模型性能优化与扩展

不断优化 MOE 模型的训练算法和架构设计,提高模型的训练效率和预测精度。采用分布式训练技术,利用多台计算设备并行计算,大幅缩短模型训练时间,使其能够及时适应快速变化的金融市场环境。同时,通过模型压缩、剪枝等技术手段,在不显著降低模型性能的前提下,降低模型的存储和计算资源需求,便于在资源受限的生产环境中部署。设计灵活的模型扩展机制,能够方便地添加新的专家模块或调整模型结构,以应对不断涌现的新型金融风险和业务需求。

1.3.实时风险监测与响应

建立基于 MOE 模型的实时风险监测系统,能够对金融市场数据进行实时流式处理和分析。通过设计高效的在线推理算法,确保模型能够在极短的时间内对新到达的数据进行处理并输出风险评估结果。一旦监测到异常风险信号,系统能够立即触发预设的风险应对机制,如自动调整交易策略、发出风险预警通知等,实现对金融风险的实时、自动响应,最大限度地降低风险损失。

2.产品目标

2.1.精准风险评估与预警

利用 MOE 模型整合多源数据,构建全面且细致的风险评估体系。通过对海量历史数据、实时市场数据以及宏观经济数据等的深度分析,精确识别各类潜在金融风险,包括信用风险、市场风险、流动性风险等。为每一个金融产品或业务线设定个性化的风险指标阈值,一旦风险水平临近或突破阈值,系统立即触发精准的预警信号,确保风险信息能够及时、准确地传达给相关决策人员,以便提前采取应对措施。

2.2.智能风险策略定制

基于 MOE 模型强大的学习和决策能力,为不同类型的金融产品量身定制智能化的风险应对策略。针对高风险产品,如复杂衍生品或高杠杆投资工具,模型可制定动态的风险对冲方案,实时调整对冲比例和工具选择,有效降低风险敞口。对于中低风险产品,如稳健型基金或固定收益类证券,模型能够优化资产配置策略,在保证收益稳定性的前提下,适度提高资金使用效率。同时,随着市场环境和产品特性的变化,MOE 模型可自动对风险策略进行适应性调整,确保策略的有效性和时效性。

2.3.优化产品定价与收益管理

借助 MOE 模型对金融风险的精准量化，实现金融产品定价的精细化和科学化。充分考虑风险因素在定价中的作用，使产品价格能够准确反映其内在风险水平，避免因定价过高或过低导致的市场竞争力下降或潜在亏损。在收益管理方面，MOE 模型通过对风险 - 收益关系的深入分析，为产品设定合理的收益目标区间，并提供实现该目标的最优投资组合和风险控制方案。在市场波动较大时，模型可及时调整投资组合权重，在控制风险的前提下，最大程度地捕捉获利机会，实现产品收益的稳定增长。

3.市场目标

3.1.增强市场竞争力

金融机构借助 MOE 模型精准识别、评估和应对金融风险，能更稳健地运营，与那些风险把控能力弱的同行相比，可凭借低风险优势吸引更多客户，无论是投资者还是借贷者，从而在激烈的金融市场竞争中脱颖而出，占据更大的市场份额。

3.2.优化投资决策

MOE 模型可深入分析海量的市场数据及各类资产相关信息，准确预估不同投资产品的风险收益情况，帮助投资者做出更明智的投资决策，筛选出风险和回报匹配度更高的投资标的，进而提升整个投资市场的效率与效益。

3.3.改善资产质量

对于金融机构而言，利用 MOE 模型有效防控风险，比如精准把控信贷风险，能减少不良资产的产生，提高资产的整体质量，使资产组合更健康、更具价值，在市场上也更具吸引力，利于后续的资产流转、处置等市场活动。

3.4.推动金融产品创新

基于 MOE 模型对风险的精准把控，金融机构有信心去研发推出更多样、更贴合市场需求的金融产品，因为可以提前对产品潜在风险进行合理预估和管控，满足不同客户群体在风险偏好、收益预期等方面的差异化需求，进一步活跃金融市场。

3.5.提升市场定价合理性

通过 MOE 模型详细分析风险因素，金融机构能够更精准地为金融产品定价，使价格能更好地反映产品实际包含的风险水平，避免因风险误判导致的定价不合理情况，促进金融市场形成更科学、有序的价格体系。

4.社会效益目标：

4.1.维护金融市场稳定

MOE 模型凭借其能整合多个“专家”模块优势，精准分析复杂的金融市场数据，提前预警如系统性金融风险、局部市场动荡等情况，有助于监管部门和金融机构及时采取措施，避免金融市场出现大幅波动，保障广大投资者的权益，维护整个金融市场稳定有序的运行环境。

4.2.促进经济健康发展

通过准确识别金融风险，比如信贷风险、流动性风险等，金融机构可以合理配置资金，将资源精准投向更有潜力、更健康的实体经济领域，避免资金流入高风险、低效益项目，保障实体经济获得稳定资金支持，进而推动各产业健康发展，促进整体经济良性循环。

4.3.保护消费者权益

MOE 模型帮助金融机构更精确地评估客户风险状况，在信贷业务等方面就能为消费者提供更合理、公平的服务条款，避免不合理的拒贷或者高息放贷情况，也能防止消费者因不了解金融产品隐藏风险而遭受损失，切实保护普通消费者在金融消费过程中的权益。

4.4.提升金融行业公信力

运用 MOE 模型实现高效且精准的金融风险管理，能减少金融机构因风险把控不当出现的违约、破产等负面事件，使得民众对整个金融行业更有信心，提升金融行业在社会大众心中的公信力，利于金融行业持续健康地服务社会。

4.5.助力社会资源合理分配

准确判断金融风险可以引导社会资金流向，让资本朝着风险可控且社会效益高的方向流动，比如流向绿色金融项目、普惠金融相关领域等，使得社会资源得到更合理的分配，推动社会整体向可持续、公平的方向发展。

五、项目进度安排				
事件/时间	今年十一月至次年一月	次年二月至五月	次年六月至八月	次年九月至十一月
事项准备和项目背景调查	十一月：确定团队成员及明确项目选题 次年一月：确定各成员职责分工，基本明确研究创新目标			
项目准备与推进		次年二月：从公司官方网站，证券交易所官网，金融数据服务平台等收集信息，进行初步数据处理。 次年三月-五月：预训练 Financial risk management MoE 模型与 Language normalization System		
项目中 期检查 报告的 撰写和 项目成 果准备			次年六月：测试 Financial risk management MoE 模型与 Language normalization System，并根据测试结果对于 Financial risk management MoE 模型与 Language normalization System 进行多次调整与优化。	
项目持续推进与细化 ↙				次年九月：根据实际情况对模型进行测试 次年十月：继续收集反馈信息，进行优化。 次年十一月：

				项目最终检查与相关资料整理
六、项目经费预算				
	支出方向	费用（万）	详情	
人力成本	数据科学家/分析师团队	0.7	负责搭建 MOE 模型架构、进行算法优化、数据预处理与分析等核心工作。	
	风险管理专家顾问	0.6	提供专业领域知识，辅助界定风险场景、解读模型输出结果用于实际决策。	
	项目管理人员	0.4	把控项目进度、协调资源与各方沟通。	
数据相关费用	数据采集	0.5	从专业金融数据提供商获取高质量历史交易数据、市场行情数据、企业财报数据等，可能按订阅套餐收费。	
	数据标注	0.5	部分风险特征标记需人工标注，如对特殊交易行为定性等。	
技术资源	硬件设备采购/租赁	0.5	为运行复杂 MOE 模型训练与推理，需高性能服务器、GPU 集群等	
	软件授权费	0.3	使用专业统计分析、机器学习开发平台（如 SAS、IBM SPSS Modeler 等）及云计算资源（如阿里云、腾讯云相关机器学习套件）	
其他杂项	办公场地与设备	0.2	提供项目团队办公空间、桌椅、电脑等基	

			础办公设施
	培训与交流费用	0.2	安排团队参加机器学习前沿技术培训、行业风险管理研讨会等
	项目验收与评估	0.3	项目收尾阶段聘请第三方机构评估模型有效性、合规性等
总和		4.2	